AI Coding 任务设计实作作品集

Python 任务规格 参考实现 测试与评分
新建 AI 辅助实作样例 | 2026 年 10 月 24 日

本材料面向申请页面中选中的 AI Coding 任务设计方向，提供三组可以在本地运行并核对的任务样例。它展示任务规格、测试与评分如何组织，不构成专家身份证明、既往项目经历证明或官方审核结论。

材料	核验入口
完整代码包	AI_Coding_Python_实作作品集.zip
任务与评分	tasks 目录内的 SPEC.md 与 rubric.json
实际运行证据	reports/evaluation.json 与 evaluation.md
来源与个人贡献	docs/PROVENANCE.md 与 PERSONAL_REVIEW.md

可核验的结果

本次本地运行中，三份参考实现通过 60/60 个测试方法；测试发现 9/9 个预设错误候选。每题的起始代码均保留为未完成桩，供后续练习。

测试发现率仅针对人为编写的错误候选。未进行真实模型测评、性能基准、独立人工审核或官方考试。测试通过不证明测试完备，也不能替代对申请人的能力考核。

申请信息依据

截图显示证明材料链接字段上限为 1000 字，补充说明上限为 500 字，并提供文件上传入口。截图未显示上传格式、文件大小、数量与完整审核规则。提交前应查看表单实际提示。

来源与署名范围

用户目前没有提供已有仓库或相关项目经历。本包的任务、代码、测试及文字经 AI 辅助生成，本地报告由程序实际运行产生；未将这些工作归为申请人已独立完成的经历。申请人可在亲自复现与修改后补充真实贡献记录。

任务设计与评分方法

三题围绕训练数据处理和评估展开，但不涉及真实模型训练。每题分别给出函数契约、合成样例、参考实现、可执行测试、三份典型错误解法和一份评分映射。

任务	主要判断点	本地测试方法数
01 训练记录去重	稳定保留、Unicode 归一化、字段组合与复制语义	20
02 按组划分	同组隔离、固定排序、舍入规则与记录顺序	20
03 多分类评估	混淆矩阵方向、零分母、宏平均与微平均	20

把歧义先写进任务书

任务书先规定输入和输出、允许的空值、顺序、异常类型与不修改输入等约束。按组划分的比例以组数为单位；分类指标的标签顺序由调用者提供。参考实现与测试都应服从这些明确约定。

用独立预期值检查行为

测试采用手算样例、固定预期结果与结构性质检查，不用参考实现的输出充当期望值。一个方法可包含多个子测试；只要其中一项失败，该方法的分值就不获得。计数单位始终是测试方法。

分数与测试逐项对应

每题 rubric.json 把测试方法映射为正整数分值，合计 100 分。运行器检查名称、唯一性与总分，再把结果和日志写入 JSON。该分数用于演示可追踪的评分设计，不是平台评分或专家通过线。

通过错误解法检查测试敏感度

每题三个候选有意引入不同缺陷。测试失败只说明发现了该候选的至少一个问题，不能证明覆盖全部同类缺陷。参考答案与测试均公开，这套材料适合展示与学习；正式测评应另建未泄露的独立测试。

运行边界

运行器为候选启动独立 Python 子进程，设置 45 秒超时并记录源码 SHA256。这有助于复现，不能作为执行不可信代码的安全沙箱。

任务一 训练记录稳定去重

目标是在不修改原始记录的前提下，保留比较键第一次出现的记录及顺序。默认把 prompt 与 response 共同作为比较键，附加元数据不参与去重。

solve(records, *, key_fields=('prompt', 'response'), normalize=True)

契约项目	明确行为
输入	list 内含 dict；字典键为字符串；选定比较字段必须存在且为字符串。
配置	key_fields 是非空且无重复的字符串元组；normalize 只接受真正的 bool。
比较	启用时依次做 NFKC、casefold、strip；内部空白不合并。关闭时精确比较原字符串。
返回	新列表及保留字典的浅拷贝；保留完整原始值；嵌套元数据按浅拷贝语义共享。
错误	类型不符抛 TypeError；缺失字段、空配置或重复字段抛 ValueError。

一个可以手算的样例

两条记录的 prompt 分别为“ A ”与“a”，response 分别为“Straße”与“STRASSE”。开启归一化时它们的比较键一致，只保留第一条原始记录；关闭归一化则两条都保留。

测试如何区分错误

大小写测试包含 ß 与 SS、希腊字母形态；字段边界测试区分 (ab, c) 与 (a, bc)；复制测试检查顶层字典隔离而嵌套引用保留；固定种子的样本以预先生成的整数标签提供独立预期。

三份错误候选

最后一条覆盖第一条；以 lower 代替 casefold；只使用第一个比较字段。这些实现保留未变更部分的校验逻辑，帮助把测试失败定位到预设缺陷。

适用限制

这只是精确规范化键去重，不是语义重复检测。NFKC 可能合并在某些业务里应区分的字符；归一化还取决于当前 Python 的 Unicode 数据库。复杂度假设及完整错误契约见该题 SPEC.md。

任务二 按组划分训练与验证集

目标是让同一 group 的全部记录进入同一集合，按组数量选择验证集，同时使选择不依赖输入行的排列。记录的输出顺序仍与原输入一致。

solve(records, validation_fraction, seed=0)

契约项目	明确行为
输入	记录列表，每条记录含非空字符串 group；比例为 0 到 1 的有限 int 或 float，排除 bool。
组数	以 Fraction(str(fraction)) 精确表示十进制比例，按 floor(组数 × 比例 + 0.5) 舍入。
固定选择	把 [seed, group] 编码为紧凑 ASCII JSON，按其 SHA256 值排序；哈希相同按组名字典序。
输出	返回 train 与 validation 两个列表；组不跨集合，保留记录顺序与原记录对象。
不变性	相同组集合、比例和 seed 的组分配相同；输入行排列可改变输出行顺序。

比例的具体含义

若只有一个组、比例为 0.5，按约定舍入后验证集有一个组。若一组有 99 条、另一组有 1 条，选择一半的组不意味着选择一半的记录。任务用明确契约消除这类常见歧义。

测试如何发现数据泄漏

测试检查训练与验证的 group 集合不相交、全部记录恰好分配一次、输出维持原始相对顺序，并用输入排列变化检查组选取的不变性。舍入的半整数边界与不同 seed 的确定性也单独验证。

三份错误候选

直接按记录随机采样可能把同组拆开；使用内置 round 会在半整数边界采用另一套舍入规则；按组首次出现顺序选择会使划分依赖输入顺序。

适用限制

只隔离显式相同的 group，不检测跨组的语义重复，也不保证标签分布平衡或记录比例。SHA256 排序用于确定性选择，不构成密码学安全或随机抽样质量的证明。详细数据格式与异常规则见 SPEC.md。

任务三 单标签多分类指标

目标是按调用方给定的 labels 顺序构建混淆矩阵，并返回逐类 precision、recall、F1，以及 macro-F1 和 micro-F1。

solve(y_true, y_pred, labels)

契约项目	明确行为
矩阵方向	行代表真实标签，列代表预测标签；标签顺序严格采用 labels。
逐类统计	TP 为对角线；FP 为列和减 TP；FN 为行和减 TP；support 为行和。
指标	precision = TP/(TP+FP)，recall = TP/(TP+FN)，F1 = 2TP/(2TP+FP+FN)。
零分母	该项返回 0.0；显式给出的未出现类别也参与宏平均。
严格校验	拒绝长度不一致、重复或未知标签以及契约不接受的类型；不修改输入。

一个可以手算的样例

labels 为 [a, b]；真实值为 [a, a, b]，预测值为 [a, b, b]。矩阵是 [[1, 1], [0, 1]]；a 类 precision 为 1、recall 为 0.5，b 类分别为 0.5 和 1。两类 F1 均为 2/3，因此 macro-F1 和 micro-F1 都为 2/3。

不平衡与零出现类别

宏平均先算每个显式标签的 F1 再求均值；微平均先汇总 TP、FP 和 FN。某类别从未出现时，零分母约定会影响宏平均。测试同时检查标签置换、全对、全错、空样本和不平衡情形。

三份错误候选

把混淆矩阵行列颠倒；用样本量加权 F1 代替宏平均 F1；宏平均时忽略未出现的标签。每个缺陷都由具体测试触发，日志可回溯到失败方法。

适用限制

适用于明确列出标签的单标签多分类，不包含多标签、样本权重、概率、阈值选择或置信区间。本包没有声称复刻某个外部库的默认行为；完整返回结构以该题 SPEC.md 为准。

本地运行与评估证据

运行时间 2026-10-24T14:59:45+08:00，时区 UTC+08:00，Python 3.12.14。以下分数由随包运行器生成；测试方法数不含方法内部子测试。

任务	候选实现	通过方法	样例分数
t01	reference	20/20	100/100
t01	starter	0/20	0/100
t01	mutant_last_wins	13/20	65/100
t01	mutant_lowercase	19/20	95/100
t01	mutant_first_field	18/20	90/100
t02	reference	20/20	100/100
t02	starter	0/20	0/100
t02	mutant_row_split	11/20	55/100
t02	mutant_bankers_rounding	18/20	90/100
t02	mutant_first_seen_groups	12/20	60/100
t03	reference	20/20	100/100
t03	starter	0/20	0/100
t03	mutant_transposed	11/20	55/100
t03	mutant_weighted_macro	14/20	70/100
t03	mutant_drop_unused	18/20	90/100

复现方式

解压源码包后，进入含 README.md 的目录，运行 python evaluate.py。仅使用 Python 标准库，无需访问网络。每次运行会更新 reports 中的 JSON 与 Markdown 报告。

JSON 保留逐方法结果、原始日志及源文件 SHA256。参考实现必须全部通过，预设错误候选与未完成起始桩被发现后，运行器才以成功状态结束。此成功状态仅表示本包检查符合预期，不表示任何人通过了官方审核。

个人复现与申请材料使用

先形成自己可以说明的贡献

建议先选择一题，在不查看参考实现的情况下独立完成 starter；然后运行测试、分析失败原因，补充至少一个新边界案例，再把实际日期、修改和日志填入 PERSONAL_REVIEW.md。未实际完成的内容保留空白，不作为已完成证明。

准备解释的内容

说明一次具体的失败和修复；解释按组比例与按记录比例的差别；手算一组混淆矩阵和 F1；指出公开测试仍可能遗漏的行为。仅重复代码或已有报告不能体现个人理解。

补充说明参考文本

本次提供一组新建的、经 AI 辅助生成的 Python 任务设计实作样例，覆盖训练记录去重、按组划分数据集和多分类指标评估。材料包含任务规格、参考实现、边界测试、评分规则、典型错误候选及本地运行报告。本次尚未提供可核验的既往相关项目材料，不将这些样例表述为过往独立成果。AI 辅助范围已在来源说明中披露，个人复现与修改记录将按实际完成情况补充。请据作品内容及后续考核评估我的能力。

该文本小于截图所示的 500 字上限；如个人事实发生变化，应据实调整。独立文本文件另附填写说明。

链接与附件

目前没有公开仓库链接。若平台要求链接，应先发布到自己的真实仓库并检查审核人员访问权限，再填写真实地址。本地文件路径、下载路径和占位 URL 均不能充当公开仓库链接。可按页面实际限制上传本 PDF 与源码包。

本材料的使用边界

本作品集没有虚构论文、证书、工作经历或官方背书。样例可供展示与练习，其内容及 AI 辅助范围均应如实披露。是否准入由平台按其规则和考核决定。